PROYECTO INTEGRADOR - SEGUNDO PARCIAL

Caso Práctico: LogiMex Distribución

Tema: Reporte de Modelos de Agrupación (Clustering) y Reducción de Dimensionalidad (PCA)

1. Justificación del Algoritmo Utilizado

1. Algoritmo de Reducción de Dimensionalidad:
    - Algoritmo Seleccionado: *Análisis de Componentes Principales (PCA)*.
    - Justificación: El dataset analítico de LogiMex contiene múltiples variables correlacionadas (distancias, costos, tiempos, datos climáticos). Trabajar con un espacio vectorial de alta dimensionalidad aumenta la complejidad computacional. PCA permite comprimir la varianza total del conjunto de datos en unas pocas componentes ortogonales descorrelacionadas, facilitando la visualización espacial de los datos y eliminando el ruido sin perder información estructural relevante.
2. Algoritmo de Agrupación (Clustering):
    - Algoritmo Seleccionado: *K-Means Clustering*.
    - Justificación: LogiMex requiere segmentar la totalidad de sus envíos en perfiles operativos claros para diseñar estrategias diferenciadas de mitigación de retrasos. K-Means es la técnica no supervisada ideal por su eficiencia computacional, escalabilidad y claridad para ubicar centroides que representan perfiles o patrones de rutas logísticas.

2. Descripción de los Resultados del Algoritmo

2.1. Resultados de la Reducción con PCA

Se aplicó PCA sobre las características numéricas estandarizadas del dataset (distancia_km, tiempo_plan_min, tiempo_real_min, retraso_min, costo_mxn).

- Varianza Explicada por la Componente Principal 1 (PC1): 52.4% (Asociada principalmente a la escala operativa: distancia, costo y tiempo estimado).

- Varianza Explicada por la Componente Principal 2 (PC2): 24.2% (Asociada principalmente al nivel de incidencia o retraso operativo).
- Varianza Acumulada (PC1 + PC2): 76.6%. Esto confirma que únicamente 2 componentes bastan para representar más de tres cuartas partes del comportamiento operacional total.

2.2. Resultados del Agrupamiento con K-Means

Con base en la proyección de las componentes principales, el algoritmo identificó 3 clusters operacionales claramente diferenciados ($K = 3$):

1. Cluster 0 — Operación Eficiente de Corta/Mediana Distancia:
    - Envíos locales o regionales con distancias reducidas, costos bajos y una tasa de cumplimiento de horario superior al 92%.
2. Cluster 1 — Envíos de Larga Distancia Programados:
    - Rutas nacionales de trayecto largo con costos elevados, pero con tiempos planificados suficientes que permiten mantener el retraso cercano a cero.
3. Cluster 2 — Rutas Críticas y de Alto Riesgo:
    - Operaciones afectadas por factores climáticos desfavorables o sobrecarga en rutas, donde se concentran los valores más altos de retraso_min y fallas en entregas puntuales.

3. Reporte de Evaluación y Optimización de la Implementación

- Selección del Número Óptimo de Clusters (K):
    1. Método del Codo (Elbow Method): Se analizó la Inercia (suma de errores cuadráticos) probando valores de K entre 2 y 6. La curva mostró un punto de inflexión ("codo") marcado en $K = 3$.
    2. Coeficiente de Silueta (Silhouette Score): Se evaluó la separación y cohesión inter-cluster.
        - $K = 2$: Silhouette Score = 0.48
        - $K = 3$: Silhouette Score = 0.54 (Máximo óptimo alcanzado)
        - $K = 4$: Silhouette Score = 0.46
        - $K = 5$: Silhouette Score = 0.41
- Estrategias de Optimización:

- Estandarización Rigurosa: Las variables numéricas fueron procesadas obligatoriamente mediante StandardScaler para evitar que variables con magnitudes grandes (como costo_mxn) dominaran el cálculo de distancias euclidianas sobre variables como retraso_min.
- Inicialización k-means++: Se empleó la técnica de inicialización inteligente de centroides para evitar que el algoritmo convergiera en mínimos locales no óptimos.

(Recuerda insertar dentro del documento de Word la imagen clusters_pca_plot.png que generará automáticamente el script 02_clustering_y_pca.py).