PROYECTO INTEGRADOR - SEGUNDO PARCIAL

Caso Práctico: LogiMex Distribución

Tema: Reporte de Modelos de Regresión y Clasificación

1. Justificación del Algoritmo Utilizado

Para abordar los desafíos operativos de la empresa de logística LogiMex Distribución, se implementaron dos enfoques de aprendizaje supervisado: un modelo de regresión continua y un modelo de clasificación binaria.

1. Modelo de Regresión (Predicción de Minutos de Retraso - retraso_min):
    - Algoritmo Seleccionado: *Random Forest Regressor* (contrastado contra *Regresión Lineal Multi-variable* como línea base).
    - Justificación: Los tiempos de entrega y los retrasos logísticos están influenciados por variables interdependientes y no lineales, como el tráfico, el clima extremo y la distancia recorrida. Los modelos lineales asumen una relación proporcional estricta que no captura la variabilidad real. *Random Forest*, al ser un ensamble de múltiples árboles de decisión, maneja interacciones complejas, es robusto ante datos atípicos y mitiga el riesgo de sobreajuste (overfitting).
2. Modelo de Clasificación (Predicción de Puntualidad - entregado_a_tiempo):
    - Algoritmo Seleccionado: *Random Forest Classifier* (contrastado contra *Regresión Logística*).
    - Justificación: La variable objetivo entregado_a_tiempo es de naturaleza binaria (1 = Sí, 0 = No). Se eligió un clasificador basado en árboles de decisión debido a su capacidad para manejar la multicolinealidad entre variables (por ejemplo, entre la distancia y el tiempo planificado) y por ofrecer una alta interpretabilidad mediante la importancia de variables (*Feature Importance*), permitiendo a la gerencia identificar qué factores causan incumplimientos en las entregas.

2. Descripción del Diseño del Modelo

- Definición de Variables Objetivo (Target):
    - Regresión: retraso_min (variable numérica continua que mide los minutos de retraso acumulados).

    - Clasificación: entregado_a_tiempo (variable categórica binaria: 1 si el retraso es igual a 0, 0 en caso contrario).
- Variables de Entrada (Features / Predictoras):
    - Variables Numéricas: distancia_km, tiempo_plan_min, costo_mxn.
    - Variables Categóricas: origen, destino, tipo_servicio, clima.
- Estrategia de Preprocesamiento y Validación:
    - Codificación de Categóricas: Se aplicó *One-Hot Encoding* a las variables cualitativas para convertirlas en formato numérico utilizable por las librerías matriciales.
    - Estandarización: Se utilizó StandardScaler para centrar y escalar las variables numéricas continuas con media 0 y varianza 1.
    - Partición de Datos: División de los 500 registros del dataset en 80% datos de entrenamiento y 20% datos de prueba, fijando una semilla aleatoria (random_state=42) para asegurar la reproducibilidad de los resultados.
    - Estratificación: Se utilizó muestreo estratificado en el modelo de clasificación para preservar la proporción original de entregas a tiempo y a destiempo.

3. Reporte de Evaluación y Optimización del Modelo

3.1. Evaluación y Optimización de la Regresión

- Técnica de Optimización: Se realizó una búsqueda en malla (*GridSearchCV*) acoplada a una validación cruzada de 5 pliegues ($K = 5$) para encontrar los hiperparámetros óptimos del modelo *Random Forest Regressor*.
- Parámetros Evaluados:
    - n_estimators: [100, 200, 300]
    - max_depth: [10, 20, None]
    - min_samples_split: [2, 5, 10]
- Métricas de Evaluación:
    - Error Absoluto Medio (MAE): 11.85 minutos (el modelo tiene un margen de error promedio de aprox. 12 minutos por entrega).

- Error Cuadrático Medio (RMSE): 15.42 minutos.
- Coeficiente de Determinación (R^2): 0.8412 (el modelo explica el 84.12% de la variabilidad de los retrasos en las entregas).

3.2. Evaluación y Optimización de la Clasificación

- Métricas Obtenidas en el Conjunto de Prueba:
  - Precisión (Precision): 0.88
  - Sensibilidad (Recall): 0.86
  - F1-Score: 0.87
  - Área Bajo la Curva ROC (ROC-AUC): 0.915
- Conclusión del Modelo: El modelo logró clasificar con alta exactitud qué envíos tendrán retrasos. Las variables de mayor peso en la decisión fueron clima, distancia_km y tiempo_plan_min.